

Christophe

Marsalotto

SCIA

2021

FTM L

1

Exercice 1

a) Matrice de confusion

Estimation 1

y'	T	6	8
F	T	1	2
	T	6	
	y		

Estimation 2


y'	T	4	1
F	T	3	9
	T	4	
	y		

Fonction de perte :

$$\begin{cases} LF(y, y') = 1, (y, y') = (F, T) \\ LF(y, y') = x, (y, y') = (T, F) \end{cases}$$

$$LF_{Est_1}(x) = (8x + 1) \frac{1}{17} \quad \text{taille de l'échantillon (non pris en compte dans le graphique)}$$

$$LF_{Est_2}(x) = (x + 3) \frac{1}{17}$$



$- LF_{Est_2}$
$- LF_{Est_1}$

b) On suppose que $x = 2$

À une constante multiplicatrice près, on a :

$$LF_{\text{Est}_1}(2) = 17$$

$$LF_{\text{Est}_2}(2) = 5 < LF_{\text{Est}_1}(2)$$

L'estimateur 2 est plus précis si $x = 2$.

c)

Pour la suite de l'énoncé, nous allons construire un estimateur bayésien naïf.

Remarque : je n'ai pas compris la question b).

On pourra donner une nouvelle colonne Y tel que

$Y_{\text{-EST}} :$

T
F
T
F
T
F
F
T
F
F
T
F
F
T

Néanmoins, cet estimation ne pourra pas se faire car il devrait à la fois répondre True pour $(x_1, x_2) = (2, 7)$ et False pour $(x_1, x_2) = (2, 1)$. Ce qui n'est pas possible avec nos données (il en manque).

d)	$Y = \text{True}$	1	2	Σ
	x_1	5	2	7 ✓
	x_2	2	5	7
	$Y = \text{False}$	1	2	
	x_1	3	7	10 ✓
	x_2	6	4	10

e)

$$\underline{\text{Cas 1: }} P(Y = T) = ?$$

On calcule :

$$P(Y = T) \times \prod_i P(x_i = k_i \mid Y = T)$$

$$= \frac{7}{17} \times \prod_i \frac{k_i}{7}$$

$$\underline{\text{Cas 2: }} P(Y = F) = ?$$


On calcule :

$$P(Y = F) \times \prod_i P(x_i = k_i \mid Y = F)$$

$$= \frac{10}{17} \times \prod_i \frac{k_i}{10}$$

Exercice 2:

a)



JVA modèle 2

SVM modèle 1

Les méthodes suivantes sont capables d'effectuer ce clustering (non-supervisé) :

- K-means (moins bien que les 2 suivantes)
- DBSCAN
- Regroupement hiérarchique (CAH par exemple)

b)

c) Il n'est pas possible d'obtenir une séparation parfaite de ces 2 clusters avec un SVM linéaire car il existe pas de droite passant entre les 2 nuage de points.

d) q. a)

Plus la pénalisation est grande, moins le modèle laisse passer de classe. SVM Linéaire 2 a donc une plus forte pénalisation.

Exercice 3

a) On a un tableau d'effet croisé et on veut savoir si les variables sont indépendantes :

On choisit une p -value de 0,05, valeur minimale (utilisée en sociologie) à partir de laquelle l'hypothèse d'indépendance ne sera pas rejetée.

On calcule le χ^2 (chi^2) avec l'outil chi^2 -contingency() et la p -value.

Si p -value < 0,05, on conclut que les variables sont bien indépendantes.


△ Pour être plus rigoureux, une analyse statistique prenant en compte les degrés de libertés des variables est nécessaire.

b) La surface d'une sphère peut pulvériser 3 points alignés mais pas 4.

$$m = 3$$



$$m = 4$$



\Rightarrow Vapnik - Chervonenkis à une dimension de 3.

c) Différence entre risque et ambiguïté.

Risque : réfère aux décisions avec des probabilités explicites

Ambiguité : réfère aux décisions sans connaissance des probabilités explicites
 \Rightarrow la prise de décision est bloquée