

# FTML 2020

## Exercice 1

a) Pour  $Y\_EST\_1$   
 en IP  $yra$  - 8 flux positifs  
 - 1 flux négatifs

$$LF_{EST1} = \frac{8 \times 1 + 1 \times x}{17} = \boxed{\frac{8+x}{17}}$$


•  $Y\_EST\_2$   
 IP  $yra$  - 1 flux positif  
 - 3 flux négatifs

$$LF_{EST2} = \frac{1 \times 1 + 3 \times x}{17} = \boxed{\frac{1+3x}{17}}$$

$$LF_{EST1} > LF_{EST2} \Leftrightarrow 8+x > 1+3x$$

$$\Leftrightarrow \boxed{x < \frac{7}{2}}$$

b) On peut construire un arbre binaire de sorte à minimiser le risque empirique



Ce qui donne un risque empirique de  $LF = \frac{1 \times 2 + 3 \times 1}{17} = \frac{5}{17}$



alors que pour  $x = 2$ ,

$$LF_{EST1} = \frac{10}{17}$$

et

$$LF_{EST2} = \frac{7}{17}$$

c) - Nous avons des informations sur les éventuelles corrélations entre les valeurs de  $X_1$  et  $X_2$ , et les valeurs de  $Y$ . On peut donc avoir un raisonnement plus intelligent qu'un bayésien naïf.

d)

$Y=T$	$X=1$	$X=2$
$X_1$	5	2
$X_2$	2	5

$Y=F$	$X=1$	$X=2$
$X_1$	3	7
$X_2$	6	4

$$e) P(Y=T | X_1=1 \text{ et } X_2=1) = \frac{P(X_1=1 | Y=T) P(X_2=1 | Y=T) P(Y=T)}{P(X_1=1 \text{ et } X_2=1)}$$

$$P(Y=T) = \frac{7}{17}$$

$$= \frac{\frac{5}{7} \times \frac{2}{7} \times \frac{7}{17}}{\frac{3}{17}} = \frac{10}{21} \approx 0,48$$

$$P(Y=T | X_1=1 \text{ et } X_2=2) = \frac{\frac{5}{7} \times \frac{5}{7} \times \frac{7}{17}}{P(X_1=1 \text{ et } X_2=2)} = \frac{\frac{5}{7} \times \frac{5}{7} \times \frac{7}{17}}{\frac{5}{17}}$$

$$= \frac{5}{7} \approx 0,71$$



$$P(Y=T | X_1=2 \text{ et } X_2=1) = \frac{\frac{2}{7} \times \frac{2}{7} \times \frac{7}{17}}{\frac{5}{17}} = \frac{4}{35} \approx 0,11$$

$$P(Y=T | X_1=2 \text{ et } X_2=2) = \frac{\frac{2}{7} \times \frac{5}{17} \times \frac{7}{17}}{\frac{4}{17}} = \frac{5}{14} \approx 0,36$$

On calcule les valeurs de  $Y=F$  maintenant


$$P(Y=F | X_1=1 \text{ et } X_2=1) = \frac{\frac{3}{10} \times \frac{6}{10} \times \frac{10}{17}}{\frac{3}{17}} = \frac{3}{5} \approx 0,6$$

$\Rightarrow P(Y=F)$  est meilleur pour  $X_1=1, X_2=1$

On compare les valeurs pour les autres valeurs de  $X_1, X_2$ :



- $X_1=1, X_2=2 \Rightarrow Y=T$
- $X_1=2, X_2=1 \Rightarrow Y=F$
- $X_1=2, X_2=2 \Rightarrow Y=F$

Cela donne donc l'estimateur suivant:



C'est donc le même estimateur que plus haut.

### Exercice 2





Une méthode non supervisée pouvant être efficace est l'agglomérative clustering, OPTICS, DBSCAN.

c) Il est possible de séparer les composantes (plus ou moins) avec un SVM linéaire, avec plus ou moins d'erreur selon le coefficient de pénalisation. Ce n'est cependant pas efficace et pas approprié.

d) (voir graphique en a)

e) Une pénalisation polynomiale permettrait de séparer les deux classes.

### Exercice 3

a) Pour cela, on ~~calcul~~ calcule les effectifs croisés espérés, les effectifs croisés observés et l'écart relatif entre les 2.

c) La différence entre risque et ambiguïté est que le risque, on connaît sa probabilité, contrairement à l'ambiguïté.