

1/6

BURKART  
Loïc

Juillet 2020  
SCIA

### FTML

Ex 1 a) Pour EST-1, on a :

$$FP = 8 \quad FN = 1$$

$$\begin{aligned} ERM1 &= \frac{1}{9} (1 \times FP + x \times FN) \\ &= \frac{8}{9} + \frac{1}{9} x. \end{aligned}$$

Pour EST-2, on a :

$$FP = 1 \quad FN = 3$$

$$\begin{aligned} ERM2 &= \frac{1}{4} (1 \times FP + x \times FN) \\ &= \frac{1}{4} + \frac{3}{4} x. \end{aligned}$$

On résout alors l'inéquation :

$$ERM1 < ERM2 \Leftrightarrow \frac{8}{9} + \frac{1}{9} x < \frac{1}{4} + \frac{3}{4} x$$

$$\Leftrightarrow \frac{8}{9} - \frac{1}{4} < \frac{3}{4} x - \frac{1}{9} x$$

$$\Leftrightarrow \frac{32-9}{36} < \frac{27-4}{36} x$$

$$\Leftrightarrow \frac{23}{36} < \frac{23}{36} x$$

$$\Leftrightarrow \underline{1 < x}$$



2/6

Donc, le risque empirique de  $EST-1$  est inférieur à celui de  $EST-2$  si et seulement si  $X$  est supérieur à 1.

b) On a :

$Y = T$	$X = 1$	$X = 2$
$X1$	5	2
$X2$	2	5

$Y = F$	$X = 1$	$X = 2$
$X1$	3	7
$X2$	6	4

On peut construire, sans hypothèse, l' $EST-3$  qui minimise le risque :

$X1$	$X2$	$Y$	$Y-EST-3$
1	2	T	T
2	2	F	F
1	1	T	T
1	2	F	F
2	2	T	T
2	1	F	F
2	2	T	T
2	1	F	F
1	1	T	T
1	2	F	F
1	1	T	T
2	1	F	F
2	2	T	T
2	1	F	F
1	2	T	T

$$ERM-3 = 0.$$



3/6

1/c) Il n'était pas nécessaire de se placer dans le cadre du bayésien naïf car aucune hypothèse n'était faite. Ainsi, on ne fait pas l'hypothèse  $P(X_1=i \wedge X_2=j) = P(X_1=i)P(X_2=j)$ .

d) fait en début de question b) page 2.

e) Estimateur bayésien naïf:

$$\begin{aligned} P(Y=T | X_1=1 \wedge X_2=1) &= P(Y=T) P(X_1=1|Y=T) P(X_2=1|Y=T) \\ &= \frac{7}{17} \times \frac{5}{7} \times \frac{2}{7} \\ &\approx 0,41 \times 0,71 \times 0,29 \approx 0,08 \end{aligned}$$

$$\begin{aligned} P(Y=F | X_1=1 \wedge X_2=1) &= P(Y=F) P(X_1=1|Y=F) P(X_2=1|Y=F) \\ &= \frac{10}{17} \times \frac{3}{10} \times \frac{6}{10} \approx 0,59 \times 0,3 \times 0,6 \\ &\approx 0,11 \end{aligned}$$

$$P(Y=T | X_1=1 \wedge X_2=2) \approx 0,41 \times 0,71 \times 0,71 \approx 0,21$$

$$P(Y=F | X_1=1 \wedge X_2=2) \approx 0,59 \times 0,3 \times 0,4 \approx 0,07$$

$$P(Y=T | X_1=2 \wedge X_2=1) \approx 0,41 \times 0,29 \times 0,29 \approx 0,03$$

$$P(Y=F | X_1=2 \wedge X_2=1) \approx 0,59 \times 0,7 \times 0,6 \approx 0,25$$

$$P(Y=T | X_1=2 \wedge X_2=2) \approx 0,41 \times 0,29 \times 0,7 \approx 0,08$$

$$P(Y=F | X_1=2 \wedge X_2=2) \approx 0,59 \times 0,7 \times 0,4 \approx 0,17$$

$X_1$	$X_2$	$Y_{\text{EST-BN}}$
1	1	F
1	2	T
2	1	F
2	2	F




4/6

Cet estimateur a peu risque :


$$\begin{aligned} \text{ERM} &= \frac{1}{4} (1 + 3x) \\ &= \frac{7}{4} \approx 1,75. \end{aligned}$$

Ex 2 a)



Une classification non supervisée par k-means ne paraît pas pouvoir séparer ces 3 composantes. Un clustering hiérarchique serait plus adapté.

b) Pour évaluer le coût, on choisit la distance euclidienne.






5/6

2/ c) Il n'est pas possible de séparer parfaitement les 2 classes par une droite, donc on ne peut pas les séparer parfaitement avec un SVM linéaire.

d)



$\times$  1  
 $\times$  -1

Droite bleue : SVM linéaire avec  $C=1$ .

Droite verte : SVM linéaire avec  $C=100$ .

e) Pour séparer ces classes, on peut utiliser un kernel polynômial de degré 2.

On peut proposer :

$$f : (x_1, x_2) \mapsto (-0,37x_1^2 + 3,17x_1 - 0,8; x_2)$$



6/6

Ex 3

- a) Pour savoir si les deux variables sont indépendantes, on effectue un test du  $\chi^2$ . L'hypothèse nulle est l'indépendance des deux variables. On calcule alors l'écart relatif entre les deux variables. Cet écart suit une loi du  $\chi^2$ . Si l'écart entre les valeurs obtenues et les valeurs attendues pour une telle loi est trop important (p-value faible), on rejette l'hypothèse nulle.
- b) Pour connaître le nombre maximum de points réalisables à la surface d'une sphère il faut placer  $k$  points à la surface d'une sphère, puis faire deux classes et essayer de les séparer. Il faut faire ça pour toutes les classes possibles, puis avec  $k$  de plus en plus grand. Pour une certaine valeur de  $k$  on ne pourra plus séparer les classes : on a alors la borne inférieure de la dimension de Vapnik-Chervonenkis.
- c) Le risque correspond, pour un estimateur donné, la ~~la~~ moyenne des erreurs commises (avec la fonction de coût associée).  
L'ambiguïté correspond à une situation dans laquelle aucun estimateur ne peut avoir un risque nul.