Exercice 1

TF => actuel True pred False FT => actuel False pred True

| TT | TF | | FT | FF |

Matrices de confusion

Est_1

|6|1|

|8|2|

Est 2

|4|3|

|1|9|

Question 1

x = 7/2 pour que les deux estimateurs aient le même risque empirique.
 Si x vaut moins de 7/2 alors l'estimateur 2 donnerait de meilleurs résultats, sinon c'est l'estimateur 1 qui donnerait de meilleurs résultats.

Question 2

Decision Tree:

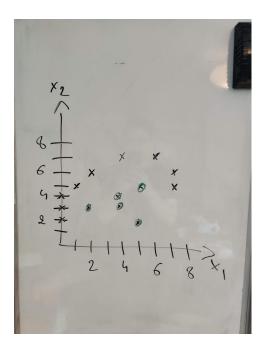
$$X1 = 1 & x2 = 2 => T$$

Ce decision tree donnerait un risque empirique de 5 avec x = 2 et les données du tableau.

Exercice 2

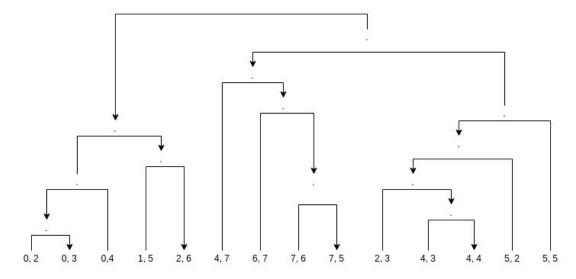
Question 1

Des méthodes de clustering, puisque les 5 derniers éléments forment un cluster trouvable



Question 2

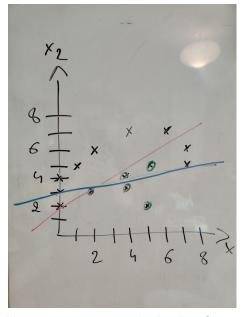
Distance de manhattan avec calcul avec le bord du cluster



Question 3

On ne peut pas tracer d'hyperplan avec les données, un SVM linéaire ne pourra donc pas séparer parfaitement les deux classes.

Question 4



Un sym en rouge qui pénalise fortement les classification de la classe interne (les 5 derniers points en vert)

Et un svm bleu avec une pénalisation plus faible

Question 5

Un kernel polynomial devrait pouvoir séparer ce genre de données.

Exercice 3

Question 1

En faisant un test de "chi squared" et en analysant la p value.

Question 2

Je place aléatoirement 2, 3, 4 points sur la sphère et j'essaie de les séparer avec un hyperplan

=> Possible puisque l'on peut insérer une pyramide dans la sphère et on sait que le coef de VC d'une pyramide est de 4

Essayer ensuite avec 5 points, de tête je ne sais pas si c'est possible

Question 3

Le risque correspond à l'analyse du nombre d'erreur sur notre entraînement.

L'ambiguite correspond elle aux predictions ou notre modele aurait une reponse mais avec une probabilité beaucoup plus faible comme dans le cas ou le point appartiendrait aux marges d'un SVM, le modele peut faire une prediction mais celle-ci aura plus de chance d'etre fausse qu'un point clairement séparé.