

Exercice 1

a) le risque empirique pour l'EST-1 :

$$\text{pred} \begin{array}{c|c} 6 & 8 \\ \hline 1 & 2 \end{array} \quad \frac{1}{17} (1 \times 8 + 2 \times 1) = \frac{8+2}{17}$$

le risque empirique pour l'EST-2 =

$$\text{pred} \begin{array}{c|c} 4 & 1 \\ \hline 3 & 9 \end{array} \quad \frac{1}{17} (1 \times 1 + 3 \times 9) = \frac{1+3 \times 9}{17}$$


$$\frac{8+2}{17} \geq \frac{1+3 \times 9}{17}$$

$$\Leftrightarrow \frac{2}{17} \geq \frac{26}{17}$$

$$\Leftrightarrow \boxed{\frac{2}{2} \geq 13}$$

si $2 \leq 13 \Rightarrow$ EST-2 est avantage
 $2 \geq 13 \Rightarrow$ EST-1 est avantage

b)



$$\frac{1}{17} \times (3 \times 2 + 1 \times 1) = \frac{5}{17}$$

c) L'arbre de décision nous permet d'avoir des résultats optimaux

d) $\text{Perm } y = \text{True}$

	1	2
x_1	5	2
x_2	2	5

$\text{Perm } y = \text{False}$

	1	2
x_1	3	7
x_2	6	4

e) $\text{Perm } y = \text{True}$

(x_1, x_2)

$$(1,1) \quad \frac{7}{17} \times \frac{5}{7} \times \frac{2}{7} = \frac{10}{119}$$

$$(1,2) \quad \frac{7}{17} \times \frac{5}{7} \times \frac{5}{7} = \frac{25}{119}$$

$$(2,1) \quad \frac{7}{17} \times \frac{2}{7} \times \frac{2}{7} = \frac{4}{119}$$

$$(2,2) \quad \frac{7}{17} \times \frac{2}{7} \times \frac{5}{7} = \frac{10}{119}$$

$\text{Perm } y = \text{False}$

(x_1, x_2)

$$(1,1) \quad \frac{10}{17} \times \frac{3}{10} \times \frac{6}{10} = \frac{9}{85}$$

$$(1,2) \quad \frac{10}{17} \times \frac{3}{10} \times \frac{4}{10} = \frac{6}{85}$$

$$(2,1) \quad \frac{10}{17} \times \frac{7}{10} \times \frac{6}{10} = \frac{21}{85}$$

$$(2,2) \quad \frac{10}{17} \times \frac{7}{10} \times \frac{4}{10} = \frac{14}{85}$$

	1	2
1	F	T
2	F	F

exercice 2

a) Voir le fichier 'question2)a.png'

On a les 9 premiers points en rouge et les 5 derniers en bleu.

On peut utiliser HCA ou KMeans pour distinguer les deux classes.

b) Voir 'dendogram.png'.

Exercice 3

a) Pour savoir si les deux variables concernées sont indépendantes, on peut utiliser le test χ^2 .

On calcule d'abord les effectifs théoriques espérés avec $\#$ étant le nombre d'événements :

$$E_{i,j} = \frac{1}{n} \# \{x=i\} \# \{y=j\}$$

Ensuite, il faut calculer les effectifs théoriques observés :

$$O_{i,j} = \# \{x=i \cap y=j\}$$

Finalement, il est possible de calculer l'écart relatif entre les deux variables :

$$T = \sum_{i,j} \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}$$

T faible signifie que les variables sont indépendantes.

b) Pour trouver le nombre maximum de points généralisables, on peut utiliser la dimension de Vapnik-Chervonenkis.

