

exercice 1:a) Pour EST-1:

Matrice de confusion:
$$\begin{array}{c|c} 6 & 1 \\ \hline 8 & 2 \end{array}$$

$$\Rightarrow \frac{1}{17} \times (1 \times 8 + x \times 1) = \frac{8+x}{17}$$


Le risque empirique, pour EST-1, est: $\frac{x+8}{17}$. noté Rep 1• Pour EST-2:

Mat. de confusion:
$$\begin{array}{c|c} 4 & 3 \\ \hline 1 & 9 \end{array}$$

$$\Rightarrow \frac{1}{17} \times (1 \times 1 + x \times 3) = \frac{3x+1}{17}$$

Le risque empirique, pour EST-2, est: $\frac{3x+1}{17}$. noté Rep 2comparaison: Soit $f: x \mapsto x+8-3x-1$ (i.e: $f(x) = -2x+7$)
 ~~$\frac{3x+8}{17}$~~ $\frac{x}{sg(f)} \mid \begin{array}{ccc} -\infty & \frac{7}{2} & +\infty \\ + & 0 & - \end{array}$ Ainsi: Pour $x \in]-\infty; \frac{7}{2}[$; Rep 1 > Rep 2 et pour $x \in]\frac{7}{2}; +\infty[$: Rep 1 < Rep 2

b) Arbre de décision:



Donc: le risque empirique vaut: $\frac{1}{17} \times (3 \times 2 + 1 \times 1) = \frac{7}{17}$

c) Un arbre de décision nous a permis d'avoir des résultats optimaux...

d) Pour y = True:

	1	2
X_1	5	2
X_2	2	5

Pour y = False:

	1	2
X_1	3	7
X_2	6	4

e) $X_1 = 1$ et $X_2 = 1$ (Δ)

(2)

$$P(Y=T \mid X_1=1 \text{ et } X_2=1) = \frac{7}{17} \times \frac{5}{7} \times \frac{2}{7} = \frac{10}{119}$$

$$P(Y=F \mid X_1=1 \text{ et } X_2=1) = \frac{10}{17} \times \frac{3}{10} \times \frac{6}{10} = \frac{9}{85}$$

$X_1 = 1$ et $X_2 = 2$ (\star)

$$P(Y=T \mid \star) = \frac{7}{17} \times \frac{5}{7} \times \frac{5}{7} = \frac{25}{119}$$

$$P(Y=F \mid \star) = \frac{10}{17} \times \frac{3}{10} \times \frac{4}{10} = \frac{6}{85}$$

$X_1 = 2$ et $X_2 = 1$ ($\$$)

$$P(Y=T \mid \$) = \frac{7}{17} \times \frac{2}{7} \times \frac{2}{7} = \frac{4}{119}$$

$$P(Y=F \mid \$) = \frac{10}{17} \times \frac{7}{10} \times \frac{6}{10} = \frac{21}{85}$$

$X_1 = 2$ et $X_2 = 2$ (∇)


$$P(Y=T \mid \nabla) = \frac{7}{17} \times \frac{2}{7} \times \frac{5}{7} = \frac{10}{119}$$

$$P(Y=F \mid \nabla) = \frac{10}{17} \times \frac{7}{10} \times \frac{4}{10} = \frac{14}{85}$$

De ce fait, nous obtenons ce tableau résumant l'estimateur bayésien naïf optimal:

	1	2
1	F	T
2	F	F


Exercice 2:



x: 9 premiers points
x: 5 derniers points.
— : Cluster 1 possible
— : Cluster 2 possible

• On pourrait utiliser un kmeans ou bien une classification hiérarchique.

b) Dendrogramme d'une classification hiérarchique ascendante.



a)

d) cf question a) (soit ~~gauche~~
droite
bleu).

e)

Exercice 3:

a) Pour vérifier l'indépendance des deux variables (noté A et B):

1) On calcule les effectifs croisés espérés:

$$E_{ij} = \frac{1}{n} \times \sum_{i,j} \text{card}(A=i) \times \text{card}(B=j)$$

2) On calcule les effectifs croisés observés:

$$O_{i,j} = \text{card}((A=i) \cap (B=j))$$

3) Enfin, on calcule l'écart entre les 2 variables. L'indépendance se traduit par une faible valeur de cet écart.

$$\chi^2 = \sum_{i,j} \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}$$