

1

## Principe

- Pulvérisation
- dimension de Vapnik–Chervonenkis

2

## SVM

- SVM linéaire
- SVM à kernel

# Décomposition du risque

$$\begin{aligned} D(\tilde{F}) - ROPT &= D(\tilde{F}) - \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) \\ &\quad + \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) - ROPT \end{aligned}$$

Comment optimiser  $Z$  ?

# Pulvérisation

Un ensemble  $X \subset E$  est dit pulvérisé par une famille de sous-ensembles  $H = (H_i \subset E)$  si :


$$H \cap X \supset 2^X$$

Autrement dit, si tout sous-ensemble de  $X$  peut être associé à un élément de  $H$ .

# Exemple

Si  $X$  est formé de 3 points non alignés du plan  $E$ , il est pulvérisé par  $H$  l'ensemble des demi-plans.

# Exemple



# Exemple



## exercice


### Exercice

*Comment peut-on pulvériser un ensemble de trois points alignés ?*

### Exercice


*Comment peut-on pulvériser un ensemble de quatre points situés aux sommets d'un carré ?*

# Exemple





# Exemple



# Pulvérisation par une famille d'estimateurs

Un ensemble  $X \subset E$  est dit pulvérisé par une famille d'estimateurs  $F = (f_i \in G^E)$  si il est pulvérisé par ses images réciproques  $(f_i^{-1}(y))$

Autrement dit, si tout sous-ensemble de  $X$  peut être discriminé par un élément de  $F$ .

# Perceptron

Le perceptron (mono-couche) à  $n$  entrées de coefficients  $w$  et de seuil  $\theta$  est défini par :

$$f : E = \mathbb{R}^p \longrightarrow \{0, 1\}$$

$$f(x) = 1 \Leftrightarrow w \cdot x > \theta$$

# Exercice

## Exercice

*Géométriquement, à quoi correspond un perceptron ? Combien de points non coplanaires est-il capable de pulvériser pour un  $p$  donné ?*

Principe

dimension de Vapnik–Chervonenkis

1

**Principe**

- Pulvérisation
- dimension de Vapnik–Chervonenkis

2

**SVM**

- SVM linéaire
- SVM à kernel

# dimension de Vapnik–Chervonenkis

$$VC(H) = \max\{i \in \mathbb{N}, \exists X, |X| = i \vee H \cap X \supset 2^X\}$$

Pour une famille d'estimateurs, la dimension de Vapnik–Chervonenkis correspond à la taille **maximale** d'un ensemble que cette famille peut pulvériser.

$$\begin{aligned} D(\tilde{F}) - ROPT &= D(\tilde{F}) - \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) \\ &\quad + \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) - ROPT \end{aligned}$$

Comment optimiser  $Z$  ?

# dimension et convergence (1)

Si  $VC(Z)$  est bornée,

$$D(\tilde{F}) - \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) \longrightarrow 0$$



# dimension et convergence (1)

Si  $VC(Z)$  est bornée,

$$D(\tilde{F}) - \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) \longrightarrow 0$$

Si  $VC(Z)$  n'est pas bornée,

$$\min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) - ROPT$$

est potentiellement meilleure.

# dimension et convergence (1)

Si les  $(X_i, Y_i)$  sont iid et

$$n = \Theta \left( \frac{VC(Z) - \log(\delta)}{\epsilon^2} \right)$$

Alors :

$$\mathbb{P} \left( D(\tilde{F}) - \min_{\tilde{g} \in Z} \mathbb{E}(LF(\tilde{g}(X), Y)) < \epsilon \right) > 1 - \delta$$

# Une situation idéale

On peut trouver des familles croissantes d'estimateurs  $Z_k$  tels que :

$$(X_i, Y_i)_{i \leq n}, n \rightarrow \infty$$

$$k \rightarrow \infty$$

$$VC(Z_k) \rightarrow \infty$$

$$VC(Z_k) \frac{\log n}{n} \rightarrow 0$$

ET

$$\min_{\tilde{g} \in Z_k} \mathbb{E}(LF(\tilde{g}(X), Y)) - ROPT \rightarrow 0$$

SVM

SVM linéaire

1

**Principe**

- Pulvérisation
- dimension de Vapnik–Chervonenkis

2

**SVM**

- SVM linéaire
- SVM à kernel

# Cas binaire

$$G = \{-1, 1\}$$

$$LF = \mathbf{1}_{Y \neq Y'}$$

$$Z = \{x \mapsto a + b \cdot x, (a, b) \in E\}$$

Un ensemble est séparable si :

$$\exists g \in Z, \forall i, g(X_i) > 0 \Leftrightarrow Y_i = 1$$


# Marge optimale

On veut optimiser :

$$\begin{aligned} & \max_{a,b} \min_i d(X_i, \Delta_g) \\ &= \max_{a,b} \min_i \frac{a + b \cdot X_i}{|b|} \\ &= \min_{\forall i, (a+b \cdot X_i) Y_i \geq 1} |b|^2 \end{aligned}$$

## Exercice

*Retrouvez graphiquement ces formules*




Marge maximale



# Cas non séparable

On veut optimiser :

$$\min_{\forall i, (a+b \cdot X_i) Y_i \geq 1 - c_i} |b|^2 + p \sum c_i$$




On se ramène donc à un problème d'optimisation classique :

- méthodes quadratiques,
- méthodes de gradient,
- complexité dépendante de la pénalisation

**Exercice**

*A partir des données iris, en vous restreignant aux largeurs/longueurs de pétales, écrivez un programme qui en fonction d'une pénalité  $p$  trouve la séparation optimale. Affichez la droite de séparation pour chaque pénalité.*

## résultat



# solution

```
from sklearn import datasets, svm
from matplotlib import pyplot as plt
import numpy as np
iris = datasets.load_iris()
X, Y = iris.data[:, 0:2], iris.target
X_train, X_test, Y_train, Y_test = X[:75], X[75:], Y[:75], Y[75:]
ref = list(np.linspace(4, 7, 100))
plt.scatter(X_train[:, 0], X_train[:, 1], c=Y_train)
for p in range(5):
    vm = svm.LinearSVC(C=10**(p-2))
    vm.fit(X_train, Y_train)
    b, a = list(vm.coef_[0]), vm.intercept_[0]
    plt.plot(ref, [-b[0]*x/b[1]-a/b[1] for x in ref],
              label=str(10**(p-2)))
plt.legend()
plt.show()
```

SVM

SVM à kernel



1 Principe

- Pulvérisation
- dimension de Vapnik–Chervonenkis

2 SVM

- SVM linéaire
- SVM à kernel

# Séparabilité et dimension





# Séparabilité et dimension

Comme pour la pulvérisation, l'espérance du nombre de points séparables vérifie  $n \sim 2p$  où  $p$  est la dimension de  $E$ .

# Séparabilité et dimension

Comme pour la pulvérisation, l'espérance du nombre de points séparables vérifie  $n \sim 2p$  où  $p$  est la dimension de  $E$ .

On considère  $\Phi : E \rightarrow E'$  où  $\dim(E') > \dim(E)$ .

# Séparabilité et dimension

Comme pour la pulvérisation, l'espérance du nombre de points séparables vérifie  $n \sim 2p$  où  $p$  est la dimension de  $E$ .

On considère  $\Phi : E \rightarrow E'$  où  $\dim(E') > \dim(E)$ .

Et le problème devient

$$\min_{\forall i, (a+b \cdot \Phi(X_i)) Y_i \geq 1 - c_i} |b|^2 + p \sum c_i$$

# Problème Dual

Problème primal :

$$\min_{\forall i, (a+b \cdot \Phi(X_i)) Y_i \geq 1 - c_i} |b|^2 + p \sum c_i$$

Problème dual :

$$\max_{\sum a_i Y_i = 0, \forall i, 0 \leq a_i \leq p} 2 \sum a_i - \sum \sum a_i a_j Y_i Y_j \Phi(X_i) \cdot \Phi(X_j)$$

# Problème avec Kernel

Problème primal :

$$\min_{\forall i, (a+b \cdot \Phi(X_i)) Y_i \geq 1 - c_i} |b|^2 + p \sum c_i$$

Problème kernelisé :

$$\max_{\sum a_i Y_i = 0, \forall i, 0 \leq a_i \leq p} 2 \sum a_i - \sum \sum a_i a_j Y_i Y_j k(X_i, X_j)$$