

#### Ressources nécessaires

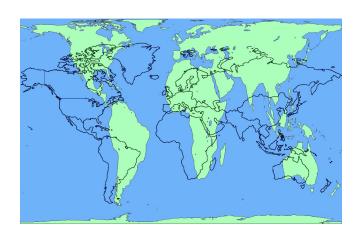
Ce cours est entièrement conçu en **Python 3**. Si vous êtes habitués à R, vous pouvez avec quelques aménagements suivre ce cours en R; pour tous les autres nous recommandons l'installation des logiciels suivants:

- Python 3.x. Si vous n'êtes pas familiers avec l'installation de packages Python, choisissez la distribution Miniconda.
- l'IDE Pyzo. Configurez le shell pour utiliser Miniconda.
- les packages suivants (via l'IDE avec conda ou en utilisant pip): NumPy, SciPy, matplotlib, pandas et sklearn

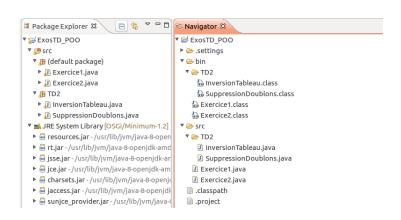




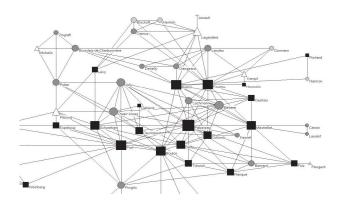








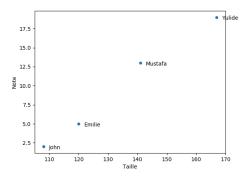




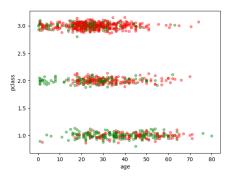












Big Data I : visualisation et traitement de données massives

Visualisation Motivation

# Problème: multidimensionnalité



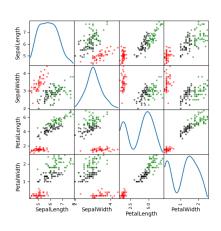
0.000 : 0.002 : 0.000 : 0.002 : 0.000 : 0.000 : 0.000 : 0.001 : 0.036 : 0.039 : 0.025 : 0.002 : 0.002 : 0.001 : 0.001 : 0.009 : 0.000 : 0.000 : 0.002 : 0.002 : 0.000 : 0.000 0.000:0.053:0.044:0.004:0.003:0.004:0.143:0.005:0.002:0.007:0.002:0.007:0.002:0.003:0.001:0.002:0.003:0.003:0.003 0.000; 0.001; 0.000; 0.0 0.000; 0.006; 0.046; 0.002; 0.001; 0.001; 0.001; 0.004; 0.001; 0.001; 0.001; 0.000; 0.008; 0.003; 0.003; 0.001; 0.000; 0.002; 0.001; 0.002; 0.002; 0.001; 0.002; 0.0 0.000; 0.0 0.000; 0.001; 0.005; 0.000; 0.0 0.000; 0.001; 0.000; 0.001; 0.000; 0.001; 0.0 0.001; 0.004; 0.004; 0.001; 0.0 0.000; 0.001; 0.000; 0.0 0.000 : 0.002 : 0.002 : 0.002 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.001 : 0.000 :0.001 :0.013 :0.000 :0.000 :0.000 :0.000 :0.001 :0.0 0.000 : 0.007 : 0.063 : 0.004 : 0.001 : 0.000 : 0.007 : 0.005 : 0.001 : 0.002 : 0.001 : 0.002 : 0.001 : 0.002 : 0.002 : 0.002 : 0.002 : 0.001 : 0.000 : 0.001 : 0.197 : 0.001





### **Scatter Matrix**





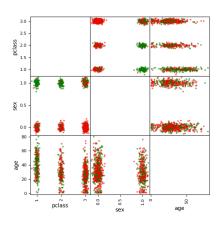
#### **Scatter Matrix**

import pandas as pd



## **Scatter Matrix**

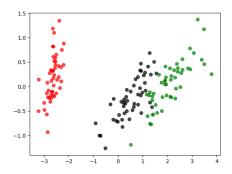




Sélection de variables

### **ACP**





import matplotlib.pyplot as plt

#### ACP



```
from sklearn import datasets
from sklearn.decomposition import PCA

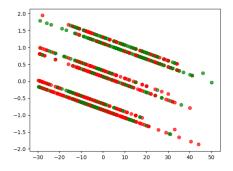
iris = datasets.load_iris()
X,Y = iris.data, iris.target
colMap={0:"red",1:"green",2:"black"}
colors=list(map(lambda x:colMap.get(x),Y))
X_2ev = PCA(n_components=2).fit_transform(X)
plt.scatter(X_2ev[:,0],X_2ev[:,1],alpha=0.7,c=colors)
plt.show()
```

Visualisation

Sélection de variables







Visualisation

Sélection de variables

## **ACP**



